



Конспект лекций

## **Финансовая эконометрика**

---

Станкевич Иван Павлович

### **Аннотация**

Курс финансовой эконометрики знакомит с основными классами моделей, используемых в финансах. Предполагается, что слушатели знакомы с эконометрикой, но ещё незнакомы с моделями временных рядов. Курс начинается с основных концепций анализа временных рядов – сюда входят базовые одномерные модели (ARIMA и ETS), коинтеграция, базовые многомерные модели. В дальнейшем рассматриваются специфичные для финансовой сферы вопросы, такие как GARCH-модель, моделирование волатильности, нелинейные модели временных рядов.

# Содержание

<b>1</b>	<b>Основные понятия теории временных рядов</b>	<b>3</b>
<b>2</b>	<b>Классический подход к теории временных рядов</b>	<b>3</b>
2.1	Автокорреляционная функция и частная автокорреляционная функция . . .	3
2.2	Методология Бокса и Дженкинса (1970) . . . . .	4
2.3	Сезонность временных рядов . . . . .	4
2.4	Тесты на единичные корни . . . . .	5
<b>3</b>	<b>Exponential Smoothing (ETS)</b>	<b>5</b>
3.1	Simple ES . . . . .	5
3.2	Component form . . . . .	5
3.3	Тренд Holt (1957) . . . . .	6
3.4	Тренд с сезонностью Holt-Winters . . . . .	6
3.5	Damped trend . . . . .	6
3.6	Prophet . . . . .	6
3.7	Кросс-валидация моделей временных рядов . . . . .	6
3.8	Model selection . . . . .	7
3.8.1	Тест Diebold-Mariano (1995) . . . . .	7
<b>4</b>	<b>Многомерные модели</b>	<b>7</b>
4.1	ARIMAX and Intervention analysis . . . . .	7
4.2	Vector autoregression . . . . .	8
<b>5</b>	<b>Байесовская векторная авторегрессия</b>	<b>8</b>
5.1	Minnesota Prior . . . . .	9
5.2	Декомпозиция дисперсии (FEVD) . . . . .	9
<b>A</b>	<b>Bootstrap sampling</b>	<b>11</b>
<b>B</b>	<b>Информационные критерии</b>	<b>11</b>

# 1 Основные понятия теории временных рядов

## 2 Классический подход к теории временных рядов

### 2.1 Автокорреляционная функция и частная автокорреляционная функция

Важный инструмент исследования временного ряда.

**Определение 1.** Пусть  $Y_t$  – стационарный в широком смысле процесс. Тогда ее автокорреляционная функция определяется как

$$\rho_k = \frac{\text{cov}(Y_t, Y_{t-k})}{\text{var } Y_t}.$$

**Уравнения Юла-Уокера** Рассмотрим стационарное решение процесса  $AR(1)$ :

$$y_t = \alpha y_{t-1} + \varepsilon_t, \quad |\alpha| < 1.$$

$$\mathbb{E}[y_t y_{t-1}] = \mathbb{E}[(\alpha y_{t-1} + \varepsilon_t) y_{t-1}],$$

откуда

$$\begin{aligned} \gamma_0 &= \alpha \gamma_1 + \sigma_\varepsilon^2, \\ \gamma_1 &= \alpha \gamma_0, \end{aligned}$$

где

$$\gamma_k = \text{cov}(y_t, y_{t-k}).$$

Итого,

$$\begin{aligned} \gamma_0 &= \frac{\sigma_\varepsilon^2}{1 - \alpha^2}, \\ \gamma_1 &= \alpha \frac{\sigma_\varepsilon^2}{1 - \alpha^2}, \\ &\dots \\ \gamma_k &= \alpha^k \frac{\sigma_\varepsilon^2}{1 - \alpha^2}, \\ &\dots \end{aligned}$$

Получившиеся уравнения называются *уравнениями Юла-Уокера*. Аналогично для стационарного решения  $MA(1)$ ,  $y_t = \varepsilon_t + \beta \varepsilon_{t-1}$ :

$$\begin{aligned} \gamma_0 &=, \\ \gamma_1 &= \beta \sigma_\varepsilon^2, \\ \gamma_2 &= 0, \\ &\dots \\ \gamma_k &= 0, \\ &\dots \end{aligned}$$

**Предложение 1.** Для стационарного решения  $MA(q)$   $ACF(k) \equiv 0$  при  $k > q$ .

**Определение 2.** Пусть  $Y_t$  – стационарный в широком смысле процесс. Тогда её частная автокорреляционная функция определяется как коэффициент  $\varphi_{k,k}$  из регрессии

$$y_t = \varphi_{k,1}y_{t-1} + \dots + \varphi_{k,k}y_{t-k} + u_t.$$

**Пример 1** ( $PACF$  для процесса  $AR(1)$ ).

$$\varphi_{k,1} = \alpha,$$

$$\varphi_{k,2} = 0,$$

...

$$\varphi_{k,k} = 0.$$

Итого,  $PACF(k) = \alpha\delta_1^k$ , где  $\delta_i^j$  – символ Кронекера.

## 2.2 Методология Бокса и Дженкинса (1970)

Авторами предлагаются следующие шаги<sup>1</sup>:

1. Ряд остационариваем разностями ( $y_t \mapsto \Delta^d y_t$ , оператор первой разности действует следующим образом:  $\Delta y_t = y_t - y_{t-1}$ );
2. Смотрим на  $ACF$  и  $PACF$ <sup>2</sup>:
  - $AR(p)$
  - $MA(q)$
  - $ARMA(p, q)$ .
3. Оцениваем  $ARIMA(p, d, q)$ .

Так уже никто не делает, но это важный этап развития эконометрической мысли. Выяснилось, что не всегда можно остационаривать ряд разностями (например, ряды с экспоненциальными трендами); стационарность определяется большим количеством тестов. Более того, для подбора параметров  $ARIMA$  можно использовать информационные критерии AIC/BIC: чем больше значение статистики, тем хуже модель.

## 2.3 Сезонность временных рядов

Сезонная модификация модели  $ARIMA - SARIMA(p, d, q) \times (P, D, Q)_S$  имеет следующий вид:

$$\begin{aligned} \Delta^d \Delta_S^D y_t = & \alpha_1 \Delta^d \Delta_S^D y_{t-1} + \dots + \alpha_p \Delta^d \Delta_S^D y_{t-p} + \\ & + \alpha_1^S \Delta^d \Delta_S^D y_{t-1} + \dots + \alpha_P^S \Delta^d \Delta_S^D y_{t-PS} + \\ & + \beta_1 \Delta^d \Delta_S^D \varepsilon_{t-1} + \dots + \beta_q \Delta^d \Delta_S^D \varepsilon_{t-q} + \\ & + \beta_1^S \Delta^d \Delta_S^D \varepsilon_{t-1} + \dots + \beta_Q^S \Delta^d \Delta_S^D \underbrace{\varepsilon_{t-QS}}_{\text{«}Q \text{ лет назад} \text{»}}, \quad (1) \end{aligned}$$

где  $\Delta_S = (1 - L^S)$  – сезонный оператор первой разности.

<sup>1</sup>Первые 2 шага называются идентификацией, третий – оцениванием.

<sup>2</sup>TODO: расписать случаи

## 2.4 Тесты на единичные корни

Это семейство тестов проверяет принадлежность корней характеристического уравнения единичной окружности.

**Тест Дики-Фуллера (Dickey-Fuller test)** Рассмотрим AP1

$$y_t = \alpha y_{t-1} + \varepsilon_t \quad | - y_{t-1}$$

$$\Delta y_t = \hat{\beta} \Delta y_{t-1},$$

$$H_0 : \beta = 0 \text{ vs } H_1 : \beta < 0,$$

$$\text{Статистика } t = \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}.$$

**Расширенный тест Дики-Фуллера (Augmented DF test)** Все ровно то же самое, но добавили предыдущие разности:

$$\Delta y_t = \dots + (\alpha - 1)y_{t-1} + \beta_1 \Delta y_{t-1} \dots + \beta_k \Delta y_{t-k} + \varepsilon_t,$$

$$H_0 : \beta = 0 \text{ vs } H_1 : \beta < 0,$$

$$\text{Статистика } t = \frac{\hat{\beta}}{\hat{SE}(\hat{\beta})}.$$

**Тест КПСС (KPSS test, 1993)** Пример теста на стационарность вокруг тренда (trend stationarity).

$$y_t = \underbrace{C_t}_{C_t = C_{t-1} + u_t} + \underbrace{\gamma t}_{\text{Линейный тренд}} + \varepsilon_t, \quad \varepsilon_t \perp u_t$$

$$H_0 : \text{var } u_t = 0 \text{ vs } H_1 : \text{var } u_t > 0,$$

**Тест Льюнга-Бокса (Ljung-Box test)** Вычислим по выборке  $\hat{\rho}_1, \dots, \hat{\rho}_k$ .  $H_0 : \hat{\rho}_1 = \dots = \hat{\rho}_k = 0$ . Статистика:

$$Q = T(T+2) \sum_{i=1}^k \frac{\hat{\rho}_i^2}{n-i} \sim \chi_k^2.$$

## 3 Exponential Smoothing (ETS)

### 3.1 Simple ES

$$\hat{y}_{T+1|T} = y_T$$

$$||$$

$$\alpha y_T + \alpha(1-\alpha)y_{T-1} + \dots$$

### 3.2 Component form

Forecast equation:  $\hat{y}_{T+h|T} = l_T$ .

Level equation:  $l_t = \alpha y_t + (1-\alpha)l_{t-1}$ .

### 3.3 Тренд Holt (1957)

Forecast equation:  $\hat{y}_{T+h|T} = l_T + hb_T$ .

Level equation:  $l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1})$ .

Trend equation:  $b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$ .

### 3.4 Тренд с сезонностью Holt-Winters

Forecast equation:  $\hat{y}_{T+h|T} = l_T + hb_T + S_{t+h-s(k-.)}$ .

Level equation:  $l_t = \alpha(y_t - S_{t-s}) + (1 - \alpha)(l_{t-1} + b_{t-1})$ .

Trend equation:  $b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$ .

Seasonality equation:  $S_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)S_{t-s}$ .

### 3.5 Damped trend

Forecast equation:  $\hat{y}_{T+h|T} = l_T + (\varphi + \varphi^2 + \dots + \varphi^h)b_T + S_{t+h-s(k-.)}$ ,  $\varphi \in (0, 1)$ .

Level equation:  $l_t = \alpha(y_t - S_{t-s}) + (1 - \alpha)(l_{t-1} + b_{t-1})$ .

Trend equation:  $b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$ .

Seasonality equation:  $S_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)S_{t-s}$ .

### 3.6 Prophet

$$y_t = \underbrace{g_t}_{\text{Trend}} + \underbrace{S_t}_{\substack{\text{Seasonality} \\ \text{сезон, недельная, внутридневная}}} + \underbrace{h_t}_{\text{Holidays}} + e_t$$

### 3.7 Кросс-валидация моделей временных рядов

$y_t, t \in \{0, \dots, N\}$

$n \leftarrow n_0$ .

**while**  $n + h \leq N$  **do**

    Строим  $\hat{y}_{n+h|n} = \hat{y}_n(y_{n-n_0}, \dots, y_n)$

$n \leftarrow n + 1$

**end while**

Другой алгоритм:

$y_t, t \in \{0, \dots, N\}$

$n \leftarrow 0$ .

**while**  $n \leq H$  **do**

    Строим  $\hat{y}_{t|t-n}$

$n \leftarrow n + 1$

**end while**

**Метрики:** MAE<sup>3</sup>, RMSE<sup>4</sup>, MAPE<sup>5</sup>, MASE<sup>6</sup>.

<sup>3</sup>Не чувствителен к разовым выбросам

<sup>4</sup>Сильно чувствителен к единичным выбросам

<sup>5</sup>Очищен от масштаба

<sup>6</sup>Относительное сравнение модели со случайным блужданием

### 3.8 Model selection

#### 3.8.1 Тест Diebold-Mariano (1995)

Сравнивает прогнозную силу моделей. Пусть  $g(\cdot)$  – некоторая функция потерь.

1.  $e_t^A = y_t - \hat{y}_t^A, e_t^B = y_t - \hat{y}_t^B$ ;
2.  $d_t = g(e_t^A) - g(e_t^B)$

$H_0 : \mathbb{E}[d_t] = 0$  vs  $H_A : \mathbb{E}[d_t] \neq 0$ . Статистика выглядит следующим образом:

$$\bar{d} = \frac{1}{k} \sum_t d_t, \quad \bar{f} = \sum_j \gamma_d(j),$$

$$S = \frac{\bar{d}}{\sqrt{\bar{f}/k}} \stackrel{H_0}{\sim} N(0, 1).$$

## 4 Многомерные модели

Если мы рассмотрим 2 независимых ряда, стационарных вокруг разных линейных трендов (но не стационарных), то выборочная корреляция будет значимо отлична от нуля. Поэтому в этой лекции рассматриваем стационарные модели рядов. В финансовой эконометрии доходности активов  $\frac{y_t - y_{t-1}}{y_{t-1}}$  обычно почти что стационарны.

Начнем с обобщений модели ARIMA.

### 4.1 ARIMAX and Intervention analysis

**Определение 3** (ARIMAX( $p, d, q$ )).

$$\Delta^d y_t = \alpha_1 \Delta^d y_{t-1} + \dots + \alpha_p \Delta^d y_{t-p} + \beta_1 \Delta^d \varepsilon_{t-1} + \dots$$

$$\dots + \beta_q \Delta^d \varepsilon_{t-q} + \gamma_1 X_{1t} + \dots + \gamma_k X_{kt}, \quad (2)$$

где  $X_{it}$  – значения стационарного ряда в какой-то момент времени (можем при помощи  $i$  сдвигать время).

Рассмотрим AR(1) модель с простым структурным срывом:

$$y_t = \alpha_0 + \alpha_1 t_{t-1} + c z_t + \varepsilon_t, \quad (3)$$

$$z_t = \begin{cases} 1, & t \geq t^*, \\ 0, & t < t^*. \end{cases} \quad (4)$$

Мгновенный эффект  $+c$ . Каков будет долгосрочный эффект?

$$\text{До:} \quad \mathbb{E}[y_t] = \alpha_0 + \alpha_1 \mathbb{E}[y_{t-1}], \quad (5)$$

$$\text{После:} \quad \mathbb{E}[y_t] = (\alpha_0 + c) + \alpha_1 \mathbb{E}[y_{t-1}]. \quad (6)$$

Долгосрочный эффект:  $+\frac{c}{1-\alpha_1}$  (если брать различие по сравнению с моментом структурного срыва).



**Определение 4.** *Impulse response function – функция следующего вида:*

$$\text{IRF} = \frac{\partial y_t}{\partial z_{t^*}}.$$

Показывает как меняется временной ряд в долгосрочной перспективе (явно выражаем  $y_t = y_{t^*+(t-t^*)}$ ).

Рассмотрим

$$y_t = \alpha(L)y_t + \gamma(L)X_t + \varepsilon_t, \quad (7)$$

где  $\alpha, \gamma$  – лаговые полиномы. Выряжая  $y$ , получаем

$$y_t = (I - \alpha(L))^{-1} \gamma(L)X_t + (I - \alpha(L))^{-1} \varepsilon_t. \quad (8)$$

Отсюда можно найти IRF по любому из  $X$ . Когда мы так делаем, мы предполагаем значимое влияние  $X$  на  $y$ , при этом  $X$  – экзогенный ряд. Но есть проблема: а что если причинность другая? Симс: "это все фигня, го ботать векторную авторегрессию".

## 4.2 Vector autoregression

**Определение 5** (VAR( $p$ )). Пусть  $y_t = [y_t^1, \dots, y_t^k]^T$ . Модель векторной авторегрессии<sup>7</sup>  $p$ -ого порядка выглядит следующим образом:

$$y_t = A_0 + A_1 y_{t-1} + \dots + A_p y_{t-p} + \varepsilon_t. \quad (9)$$

Оценка происходит построчно при помощи МНК.

Симсон предложил: мы в VAR слишком много фигни оцениваем, нам важно получить состоятельные оценки, а не эффективные.

**Пример 2** (Двумерный VAR(1)).

$$x_t = a_0 + a_1 x_{t-1} + a_2 z_{t-1} + \varepsilon_t^1, \quad (10)$$

$$z_t = b_0 + b_1 x_{t-1} + b_2 z_{t-1} + \varepsilon_t^2. \quad (11)$$

Рассмотрим VAR(1):

$$\begin{aligned} y_t &= A_0 + A_1 y_{t-1} + \varepsilon_t \\ (I - A_1 L) y_t &= A_0 + \varepsilon_t \\ y_t &= (I - A_1 L)^{-1} A_0 + (I - A_1 L)^{-1} \varepsilon_t \\ y_t &= \tilde{A}_0 + \underbrace{A_1^n y_{t-n}}_{\rightarrow 0} + \sum_{i=1}^n A_1^i \varepsilon_{t-i} \rightarrow \text{VMA}(\infty) \end{aligned}$$

## 5 Байесовская векторная авторегрессия

Замечание: BVAR – некоторое обобщение регуляризации. Байесовский VAR – это про очень большие модели с недостатком данных для точной фреквентивистской оценки.

<sup>7</sup>Интерпретируем это как «всё в прошлом влияет на всё в настоящем»

## 5.1 Minnesota Prior

**Определение 6** (Minnesota Prior). Положим  $\text{VAR}(p)$  :  $Y_t = X_t \Phi + \varepsilon_t$ ,  $\varphi := \text{vec } \Phi$ ,  $\varepsilon \sim \mathcal{N}(0; \Sigma)$ .

$$\text{Prior} \cdot \varphi \sim \mathcal{N}(\underline{\varphi}; \Xi).$$

Тогда

$$\text{Posterior} \cdot \varphi^{post} \sim \mathcal{N}(\bar{\varphi}; \bar{\Xi}).$$

Рассмотрим  $\underline{\varphi} = \mathbb{E}^{prior}[\varphi] = \text{vec } \underline{\Phi}$ <sup>8</sup>. Говорим, что модель имеет априорное распределение Миннесоты, если

$$(A_l)_{ij} = \delta \mathbb{1}(l = 1, i = j), \quad \delta \in [-1, 1].$$

**Замечание 1.** Смысл этого априорного распределения: пусть все компоненты рядов  $\text{AR}(1)$ .

**Пример 3.**  $X \sim U[0, \Theta]$ . Prior:  $\Theta \sim \text{Pareto}(\alpha, \beta)$ ,

$$f(\theta) = \begin{cases} \frac{\alpha \beta^\alpha}{\theta^{\alpha+1}}, & \theta > \beta > 0, \\ 0, & \text{else.} \end{cases}$$

Posterior:

$$f^{post}(\theta) = \mathcal{L}f(\theta) = f(\theta) \prod_{i=1}^n \frac{1}{\theta} = \frac{\alpha \beta^\alpha}{\theta^{\alpha+n+1}} \sim \text{Pareto}(\alpha^*, \beta^*),$$

где  $\alpha^* = \alpha + n$ ,  $\beta^* = \max(\beta, \max X)$ .

Далее все  $\lambda$  – гиперпараметры модели.

$$\Xi = \begin{bmatrix} \Xi_{\text{const}} & 0 & 0 & \dots & 0 \\ 0 & \Xi_1 & 0 & \dots & 0 \\ 0 & 0 & \Xi_2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \Xi_p \end{bmatrix},$$

$$(\Xi_{i,l})_{jj} = \begin{cases} \frac{\lambda_{\text{tight}}}{l^{\lambda_{\text{lag}}}}, & i = j, \\ \frac{(\lambda_{\text{tight}} \lambda_{\text{kron}} \sigma_i)^2}{(l^{\lambda_{\text{lag}}} \sigma_j)^2}, & i \neq j. \end{cases} \quad l = 1, \dots, p,$$

$$\Xi_{i,\text{const}} = (\lambda_{\text{tight}} \lambda_{\text{const}} \sigma_i)^2.$$

## 5.2 Forecasting Error Variance Decomposition

$$\begin{aligned} \hat{Y}_{T+1} &= \hat{A}_0 + \hat{A}_1 Y_T + \dots + \hat{A}_p Y_{T-p+1}, \\ Y_{T+1} &= A_0 + A_1 Y_T + \dots + A_p Y_{T-p+1} + \varepsilon_{T+1}. \end{aligned}$$

Если оценка хорошая, то она несмещенная и

$$\hat{e}_{T+1} = Y_{T+1} - \mathbb{E}[\hat{Y}_{T+1}] = \varepsilon_{T+1}.$$

Аналогично,

$$\hat{e}_{T+2} = A_1 \varepsilon_{T+1} + \varepsilon_{T+2}.$$

<sup>8</sup>восстановим  $\underline{\Phi}$  как обращение оператора  $\text{vec}$

Итого,

$$\hat{e}_{T+h;j} = a_{11}\varepsilon_{1;T+1} + a_{1n}\varepsilon_{1;T+n} + \dots + a_{k1}\varepsilon_{k;T+1} + \dots,$$

где  $j$  – номер  $y$ . То есть можем разложить итоговую ошибку как комбинацию ошибок прошлого. Поскольку можем рассматривать ортогонализированный шум, то получаем выражение для дисперсии ошибки.

## A Bootstrap sampling

Пусть  $X_1, \dots, X_n$  – выборка. Генерим семплы размера  $n$  из этой выборки (равномерно по имеющимся значениям). Делаем  $B \sim 10^3$  т.н. bootstrap samples. По каждой подвыборке оцениваем регрессию и получаем  $B$  разных оценок  $\beta_i$  в  $y = \beta_0 + \beta_1 X$ .

Для временных рядов: как попало семплить не можем, т.к. данные упорядочены во времени. Делим ряд на набор блоков и применяем к ним bootstrap sampling. Если блоки маленькие, то зависимости во времени примерно сохраняются. Такой подход называется *block bootstrap sampling*.

## В Информационные критерии

Информационные критерии: чем меньше число, тем лучше модель.

**Определение 7** (Информационный критерий Акаике). Пусть  $k$  – число оцениваемых параметров модели,  $\mathcal{L}^* = \mathcal{L}(\hat{\theta})$  – правдоподобие полученной оценки. Тогда

$$\text{AIC} = 2k - 2 \ln \mathcal{L}^*.$$

**Определение 8** (Информационный критерий Шварца-Байеса). Пусть  $k$  – число оцениваемых параметров модели,  $n$  – число наблюдений,  $\mathcal{L}^* = \mathcal{L}(\hat{\theta})$  – правдоподобие полученной оценки. Тогда

$$\text{BIC} = k \ln n - 2 \ln \mathcal{L}^*.$$